國立東華大學資訊工程學系

碩士論文

基於 YOLO26 之即時物件偵測技術演進、架構優化與 2026 年邊緣運算應用研究

Research on the Technical Evolution, Architecture Optimization, and 2026 Edge Computing Applications of Real-Time Object Detection Based on YOLO26

研究生：吳致穎
指導教授：陳文盛教授

中華民國一一五年三月

（審定書頁）

謝誌

本論文得以順利完成，首先感謝指導教授陳文盛教授於課程中悉心指導，提供完整的作業規範與學習方向。

本論文之研究內容使用 AI 深度研究工具輔助產生初稿，經本人審閱、修正與補充後完成。所有引用文獻均經確認其真實性，AI 產出內容僅作為草稿基礎，最終論文融入本人之思考與分析。

論文排版方面，本人依照國立東華大學碩士論文格式規範，於 Microsoft Word 中完成以下格式設定：套用標題樣式 1、2、3 建立章節層級；使用「參考資料→目錄」自動生成目錄；以 SEQ 欄位建立圖片與表格標號，並透過「插入→圖表目錄」自動生成圖次與表次；於正文引用圖表處使用「插入→交叉參照」功能；設定分節符號區隔封面、前置單元與正文，並分別套用羅馬數字與阿拉伯數字雙頁碼系統；最終以「另存新檔→PDF」匯出並確認字型內嵌。

研究生 吳致穎 謹誌

中華民國一一五年三月

摘要

隨著智慧工廠、自動駕駛、無人機（UAV）及物聯網（IoT）等邊緣運算（Edge Computing）場景的快速普及，電腦視覺系統對即時物件偵測（Real-Time Object Detection）的精確度與低延遲需求達到了前所未有的高度。過去十年間，You Only Look Once (YOLO) 系列模型主導了單階段（One-Stage）物件偵測領域。然而，在追求 MS COCO 基準測試極限精度的過程中，諸如非極大值抑制（Non-Maximum Suppression, NMS）後處理與分佈焦點損失（Distribution Focal Loss, DFL）等機制，逐漸成為限制模型在資源受限之邊緣硬體上部署的運算瓶頸。

本研究旨在深入探討並分析於 2026 年發布的最新一代 YOLO26 模型之技術演進與架構優化策略。YOLO26 標誌著從傳統「精度至上」向「邊緣部署優先（Edge-First）」設計哲學的重大典範轉移。本論文詳細剖析了 YOLO26 的四大核心創新：第一，原生端到端（End-to-End）的無 NMS 推論架構，澈底解決了延遲不確定性與後處理負載問題；第二，移除 DFL 以簡化邊界框回歸，大幅消除了模型導出至 TensorRT、OpenVINO 與 CoreML 等邊緣推論引擎時所面臨的「導出鴻溝（Export Gap）」；第三，首創引入結合大型語言模型（LLM）訓練經驗的 MuSGD (Momentum-Unified Stochastic Gradient Descent) 混合優化器，利用牛頓-舒爾茨正交化（Newton-Schulz Orthogonalization）顯著提升了輕量化 R-ELAN 骨幹網路的收斂穩定性；第四，設計了漸進式損失平衡（ProgLoss）與小目標感知標籤分配（STAL）機制，完美彌補了因移除 DFL 所帶來的潛在精度損失，特別在微小物件的召回率上展現了卓越的效能。

本研究於實驗方法中建構了嚴謹的硬體基準測試（Benchmarking）環境，評估平台包含 NVIDIA Jetson Orin Nano、AGX Orin 及最新一代 AGX Thor 邊緣運算設備。實驗數據分析表明，相較於前代 YOLO11 與 YOLOv8，YOLO26 在中央處理器（CPU）上的推論速度提升高達 43%。在 MS COCO 驗證集上，YOLO26x 超大型變體以 57.5% 的 mAP（平均精度均值）奠定了新的 Pareto 前緣（Pareto Front），

並在無 NMS 的推論條件下維持了極低的模型參數量與運算複雜度（FLOPs）。此外，本論文亦詳盡探討了 YOLO26 統一架構在實例分割、姿態估計、定向邊界框（OBB）以及結合 YOLOE-26 之開放詞彙（Open-Vocabulary）等多任務領域的擴充性。綜合各項分析，本研究證實 YOLO26 成功跨越了學術理論與工業落地間的鴻溝，作為 2026 年邊緣人工智慧（Edge AI）基礎模型，展現出巨大的實用價值與學術啟發。

關鍵字： YOLO26、邊緣運算、即時物件偵測、端到端學習、無非極大值抑制、MuSGD 優化器、區域注意力機制、R-ELAN

Abstract

With the rapid proliferation of edge computing applications such as smart manufacturing, autonomous driving, unmanned aerial vehicles (UAVs), and the Internet of Things (IoT), the demand for high precision and low latency in real-time object detection systems has reached unprecedented heights. Over the past decade, the You Only Look Once (YOLO) series has dominated the domain of one-stage object detection. However, in the pursuit of extreme accuracy on benchmarks like MS COCO, mechanisms such as Non-Maximum Suppression (NMS) post-processing and Distribution Focal Loss (DFL) have increasingly become computational bottlenecks, restricting model deployment on resource-constrained edge hardware.

This research aims to conduct an in-depth exploration and analysis of the technical evolution and architecture optimization strategies of the latest generation YOLO26 model, released in 2026. YOLO26 signifies a major paradigm shift from the traditional "accuracy-first" approach to an "edge-first" design philosophy. This thesis meticulously dissects the four core innovations of YOLO26: First, the native end-to-end NMS-free inference architecture, which completely resolves latency uncertainty and post-processing overhead. Second, the removal of DFL to simplify bounding box regression, significantly eliminating the "export gap" encountered when converting models to edge inference engines like TensorRT, OpenVINO, and CoreML. Third, the pioneering introduction of the MuSGD (Momentum-Unified Stochastic Gradient Descent) hybrid optimizer, inspired by Large Language Model (LLM) training experiences, which utilizes Newton-Schulz orthogonalization to substantially enhance the convergence stability of the lightweight R-ELAN backbone. Fourth, the design of Progressive Loss Balancing (ProgLoss) and Small-Target-Aware Label Assignment (STAL) mechanisms, which perfectly compensate for the potential accuracy loss caused by DFL removal, demonstrating exceptional performance in the recall rate of minute objects.

In the methodology, this study constructs a rigorous hardware benchmarking environment, evaluating platforms including NVIDIA Jetson Orin Nano, AGX Orin, and the latest generation AGX Thor edge computing devices. The experimental data analysis

indicates that compared to its predecessors YOLO11 and YOLOv8, YOLO26 achieves up to a 43% increase in inference speed on Central Processing Units (CPUs). On the MS COCO validation set, the extra-large YOLO26x variant establishes a new Pareto front with a 57.5% mAP (mean Average Precision) while maintaining extremely low model parameters and computational complexity (FLOPs) under NMS-free inference conditions. Furthermore, this thesis exhaustively explores the scalability of the unified YOLO26 architecture in multi-task domains, including instance segmentation, pose estimation, oriented bounding boxes (OBB), and the integration of open-vocabulary detection via YOLOE-26. Synthesizing the analyses, this research corroborates that YOLO26 successfully bridges the chasm between academic theory and industrial deployment, demonstrating immense practical value and academic inspiration as the foundational model for Edge AI in 2026.

Keywords: YOLO26, Edge Computing, Real-Time Object Detection, End-to-End Learning, NMS-Free, MuSGD Optimizer, Area Attention, R-ELAN

目錄

謝誌 i
摘要 ii
Abstract iv
圖目錄 viii
表目錄 ix

第一章 緒論 1
1.1 研究背景與動機 1
1.2 研究目的與挑戰 2
1.3 論文架構與章節安排 3

第二章 文獻探討與即時物件偵測技術演進 4
2.1 YOLO 系列之發展脈絡：從 YOLOv8 至 YOLOv13 4
2.2 邊緣運算於電腦視覺之應用與導出鴻溝 6
2.3 從「精度至上」到「邊緣優先」的設計典範轉移 6

第三章 研究方法與 YOLO26 架構優化分析 8
3.1 原生端到端無非極大值抑制 (NMS-Free) 之雙頭分配策略 8
3.2 輕量化骨幹重構：R-ELAN 與線性區域注意力機制 (Area Attention) 9
3.3 移除 DFL 之數學意涵與邊緣推論優勢 11
3.4 MuSGD 優化器與牛頓-舒爾茨正交化數學模型 11
3.5 漸進式損失平衡 (ProgLoss) 與小目標感知標籤分配 (STAL) 13
3.6 統一多任務與 YOLOE-26 開放詞彙 (Open-Vocabulary) 擴展 14

第四章 實驗設計與結果討論 16
4.1 實驗環境與基準測試設定 16

4.2 MS COCO 基準測試：精度與 CPU 延遲之權衡突破 17
4.3 邊緣硬體量化部署與 FPS 效能實測 19
4.4 消融實驗 (Ablation Study) 與機制貢獻度剖析 21

第五章 結論與未來展望 24
5.1 研究總結 24
5.2 未來研究方向 25

參考文獻 26

圖目錄

圖 1 傳統 YOLO 與 YOLO26 端到端推論架構之效能差異比較 7
圖 2 MuSGD 混合優化器依參數維度動態分配策略之示意圖 13
圖 3 YOLO26 統一骨幹架構支援多任務視覺感知之模組切換示意圖 15
圖 4 YOLO26 全系列變體於精度-延遲 Pareto 前緣之效能分布圖..... 19
圖 5 TensorRT 加速下 YOLO26 推論管道扁平化架構示意圖 21
圖 6 啟用 STAL 機制前後小目標特徵響應熱力圖比較..... 23

表目錄

表 1 2023 年至 2026 年 YOLO 系列模型核心技術演進與分歧分析表 4
表 2 YOLO26 骨幹與頸部網路之模組架構及其運算複雜度解析表 10
表 3 YOLO26 家族與歷史模型在 MS COCO 基準測試上之精度、複雜度與延遲綜合比較表..... 17
表 4 YOLO26 於不同量級 NVIDIA Jetson 邊緣運算平台之張量加速與推論 FPS 表現..... 19
表 5 YOLO26 核心創新機制對模型精度與收斂速度之消融實驗貢獻度分析表..... 21

第一章 緒論

1.1 研究背景與動機

在現代人工智慧的發展浪潮中，電腦視覺（Computer Vision, CV）技術已成為賦予自動化機器感知能力的關鍵核心。其中，物件偵測（Object Detection）作為最基礎且具備極高挑戰性的視覺任務之一，要求演算法不僅能識別影像或影片串流中存在的物體類別，還需精確標定其空間位置（以邊界框 Bounding Box 表示）(Redmon et al., 2016)。自 2015 年 Joseph Redmon 等人提出首代 YOLO (You Only Look Once) 演算法以來，電腦視覺界迎來了重大的典範轉移。YOLO 將物件偵測從傳統的兩階段（Two-Stage）候選區域提取方法（如 Faster R-CNN），轉變為單次前向傳播（Single-Pass Forward Pass）的端到端迴歸問題，確立了即時物件偵測的黃金標準 （Redmon et al., 2016）。

隨著時間的推移與深度學習運算能力的躍升，YOLO 系列經歷了無數次的架構演進。特別是從 2023 年的 YOLOv8 確立了無錨框（Anchor-Free）與解耦偵測頭（Decoupled Head）的工業標準後，學術界與產業界為追求在 MS COCO 基準測試上的極限精度，不斷於網路架構中引入複雜的特徵提取與損失函數模組 (Wang et al., 2024)。例如，利用分佈焦點損失（Distribution Focal Loss, DFL）來進行細粒度的邊界框回歸，或是引入各式自注意力機制（Self-Attention）與超圖空間建模（Hypergraph Spatial Modeling）來強化全局語義特徵 (Vaswani et al., 2017)。這些架構上的增強雖然成功推升了平均精度均值（mAP），卻不可避免地導致了神經網路運算成本的劇增，並在實際工程部署上引發了嚴重的「導出鴻溝（Export Gap）」問題（Wang et al., 2024）。

在邊緣運算（Edge Computing）場景中，如嵌入式系統、自主無人機、移動農用機器人及高頻控制之機械手臂，硬體通常缺乏如資料中心般強大的浮點運算單元（GPU Tensor Cores）。這些設備高度依賴整數運算單元（INT8 ALUs）與神經處理單元（NPU）來執行模型推論 (Shi et al., 2016)。然而，DFL 所依賴的

大量 Softmax 運算在 NPU 上執行效率極低，且傳統 YOLO 架構中不可或缺的非極大值抑制（Non-Maximum Suppression, NMS）後處理演算法，由於其運算時間高度依賴於畫面中重疊物件的數量，會導致系統的處理時間充滿不確定性（Latency Variability）(Neubeck & Van Gool, 2006)。對於要求嚴格即時性與確定性延遲（Deterministic Latency）的工業應用而言，這種架構特徵構成了不可忽視的安全與效能隱患(Geiger et al., 2012)。

有鑑於此，Ultralytics 團隊於 2026 年初正式發布的 YOLO26 模型，標誌著研究重心的歷史性轉向。YOLO26 以「邊緣部署優先（Edge-First）」為設計核心，進行了深度的「減法工程」(Ultralytics, 2026)。其徹底移除了 DFL 與 NMS，回歸極致精簡的原生端到端架構，並透過首度引入源自大型語言模型（LLM）優化技術的 MuSGD 混合優化器，結合漸進式損失平衡（ProgLoss）與小目標感知標籤分配（STAL）機制，完美填補了因移除複雜模組而流失的精度 （Wang et al., 2024）。本研究的動機即在於深入解析 YOLO26 這一重大技術跳躍的底層數學原理與網路架構，並透過嚴謹的硬體基準測試，驗證其在真實邊緣運算平台上的效能表現，以期為台灣資工學術界與產業界在部署新一代視覺系統時，提供完備的理論基礎與實務實證數據。

1.2 研究目的與挑戰

本研究的執行面臨著如何平衡模型輕量化與複雜場景偵測精度之核心挑戰。具體而言，移除 DFL 與 NMS 雖能大幅提升推論速度並消弭導出鴻溝，但亦可能造成邊界框定位精度下降與微小物件漏檢（Small Object Vanishing）的風險 (Wang et al., 2024)。因此，本研究旨在達成以下四項主要研究目的，並對應解決上述挑戰：

1. **深度剖析技術演進脈絡：** 系統性地梳理從 YOLOv8 至 YOLO26 間的架構演進史，探討學術界（如台灣學者王建堯博士參與研發的 YOLOv9、YOLOv12 等模型）與產業界在模型設計哲學上的分歧與匯流，並明確界定 YOLO26 在 R-ELAN 骨幹網路與區域注意力機制（Area Attention）上的創新融合 (Redmon et al., 2016)。
2. **解構底層演算法優化機制：** 針對 YOLO26 首度跨領域引入的 MuSGD 優化

器進行數學推導，探討牛頓-舒爾茨正交化（Newton-Schulz Orthogonalization）如何穩定輕量化網路的訓練軌跡。同時，深度分析漸進式損失平衡（ProgLoss）與小目標感知標籤分配（STAL）機制如何協同作用，克服邊緣視覺中微小物體難以收斂的挑戰 (Moonshot AI, 2024)。

3. **驗證邊緣運算效能與量化部署：** 建構基於 NVIDIA 全系列邊緣運算生態系（包含 Jetson Nano、AGX Orin、及具備高達 2070 TFLOPS 算力的 AGX Thor）的評估環境。針對 YOLO26 進行廣泛的 FPS 與 mAP 基準測試，驗證其在 INT8/FP16 量化（Quantization）及 TensorRT 加速下的實質推論效能 (Shi et al., 2016)。
4. **探討多任務統一架構與開放詞彙應用：** 評估 YOLO26 雙頭架構（Dual-Head Architecture）在實例分割、姿態估計、定向邊界框（OBB）等多模態視覺任務中的表現。並進一步探討其結合 YOLOE-26 模組實現無提示（Prompt-free）開放詞彙（Open-Vocabulary）目標偵測之前瞻應用潛力 (Radford et al., 2021)。

1.3 論文架構與章節安排

本論文共分為五章，各章節之內容安排如下：

- **第一章 緒論：** 闡述本研究之背景、動機、面臨之挑戰及具體研究目的。
- **第二章 文獻探討與即時物件偵測技術演進：** 廣泛回顧 YOLO 系列自 YOLOv8 至 YOLOv13 的發展軌跡，對比注意力機制在卷積神經網路中的應用，並探討邊緣運算於電腦視覺落地所遭遇的硬體與軟體瓶頸。
- **第三章 研究方法與 YOLO26 架構優化分析：** 為本論文之核心理論章節。深入解構 YOLO26 的原生端到端無 NMS 設計、R-ELAN 骨幹、MuSGD 優化器之數學模型，以及 ProgLoss 與 STAL 之演算法實作細節。
- **第四章 實驗設計與結果討論：** 詳述硬體實驗環境配置，呈現 MS COCO 資料集之基準測試數據，探討邊緣設備之推論延遲、FPS 表現，並透過消融實驗（Ablation Study）量化各優化模組之獨立貢獻度。
- **第五章 結論與未來展望：** 總結本研究之關鍵發現，並針對時空聯合感知（Spatiotemporal Perception）與邊緣端測試期適應（Test-Time Adaptation）

提出後續研究之建議。

第二章 文獻探討與即時物件偵測技術演進

物件偵測演算法的演進史，實為運算複雜度與預測精確度之間不斷妥協與突破的過程。本章節將回顧過去數年間 YOLO 系列架構的關鍵技術跳躍，分析台灣與國際學者在其中扮演的推動角色，並探討邊緣運算對當代視覺模型所施加的嚴格物理限制。

2.1 YOLO 系列之發展脈絡：從 YOLOv8 至 YOLOv13

自 2016 年首代 YOLO 提出以來，該演算法將物件偵測視為純粹的迴歸問題，避免了 R-CNN 系列生成候選區域（Region Proposal）的龐大開銷 （Redmon et al., 2016）。至 2023 年，由 Ultralytics 推出的 YOLOv8 確立了現代單階段偵測器的標準範式：全面採用無錨框（Anchor-Free）設計，利用解耦頭（Decoupled Head）將分類與邊界框定位任務分離，並導入了分佈焦點損失（DFL）結合 CIoU 來提升邊界框的精細度（Ultralytics, 2023）。

隨後，學術界與開源社群對 YOLO 架構進行了激烈的多線分支探索。表 1 呈現了這段時期內 YOLO 生態系的重要發展里程碑，並清晰反映出「學術導向」與「工業部署導向」兩股力量的交織。

表 1 2023 年至 2026 年 YOLO 系列模型核心技術演進與分歧分析表

模型版本 (發表年份)	主要開發團隊 / 機構	核心架構與演算法創新	標籤分配與後處理機制	發展導向與歷史意義
YOLOv8 (2023)	Ultralytics	C2f 模組、無錨框解耦偵測頭	DFL 回歸, 依賴 NMS	確立現代工業界物件偵測之通用標準架構 [22]

YOLOv9 (2024)	台灣學者王建堯等人	可程式化梯度資訊 (PGI)、GELAN 骨幹	輔助可逆分支, 依賴 NMS	從資訊瓶頸角度切入，確保深層網路梯度保留 [22]
YOLOv10 (2024)	清華大學	原生無 NMS 訓練設計、雙標籤分配	1-to-Many 與 1-to-1 雙頭	首次以端到端方式根除推論期 NMS 的單階段架構 [22]
YOLO11 (2024)	Ultralytics	C3k2 模組、高效能跨尺度特徵融合	DFL 回歸, 依賴 NMS	優化運算效率，參數量減少 22% 且精度微升 [22]
YOLOv12 (2025)	Yunjie Tian 等人	R-ELAN 骨幹、區域注意力機制 (Area Attention)	類 Transformer 設計, 依賴 NMS	將 ViT 等級精度帶入即時運算，但 CPU 效能受限 [22]
YOLOv13 (2025)	iMoonLab	超圖空間建模 (HyperACE)、FullPAD 聚合	DFL 回歸, 依賴 NMS	專注於複雜場景中的物件關聯推理能力 [8]
YOLO26 (2026)	Ultralytics	邊緣優化 CNN、移除 DFL、引入 MuSGD	STAL + ProgLoss, 原生無 NMS	回歸實用主義，徹底消除導出鴻溝，實現極致推論 [14]

4

由文獻可知，台灣學者如王建堯博士與廖弘源特聘研究員在 YOLOv4、

YOLOv7 乃至 YOLOv9 的發展中貢獻卓著。YOLOv9 提出的可程式化梯度資訊（PGI）有效解決了深度網路在前向傳播過程中的資訊流失問題 （Wang et al., 2024）。進入 2025 年，YOLOv12 與 YOLOv13 的出現代表了學術界尋求將 Transformer 架構優勢（如全局感受野）融入 YOLO 的極致嘗試。YOLOv12 提出了 R-ELAN 架構與區域注意力（Area Attention）機制，以期在維持卷積神經網路（CNN）速度的同時達到 Vision Transformer (ViT) 的高語義理解力（Wang et al., 2024）。然而，這些模型的複雜度極大，且仍保留了 DFL 與 NMS，這在資源充沛的 GPU 上表現優異，卻難以直接應用於終端設備（Vaswani et al., 2017）。

2.2 邊緣運算於電腦視覺之應用與導出鴻溝

在邊緣人工智慧（Edge AI）的實務部署中，模型通常需要在資源極度受限的硬體（如微控制器 MCU、行動裝置 NPU 或無人機載板）上運行 （Shi et al., 2016）。傳統 YOLO 模型在轉移至邊緣環境時，會遭遇嚴峻的「導出鴻溝（Export Gap）」。

導出鴻溝的成因主要有二：

1. **非極大值抑制（NMS）的延遲不確定性：** NMS 是一種序列化的啟發式演算法，用於過濾冗餘的邊界框。其時間複雜度與畫面中的預測框數量成正比。在擁擠場景（Dense Scenes）中，NMS 的處理時間可能超過網路前向傳播本身，這對於要求確定性延遲（Deterministic Latency）的自動駕駛防撞系統而言，是無法接受的架構缺陷 （Neubeck & Van Gool, 2006）。
2. **分佈焦點損失（DFL）的量化困難：** DFL 透過預測連續坐標的機率分佈來計算邊界框位置。這要求在網路的最後一層執行沿特定維度的 Softmax 操作，並計算期望值（積分）。在進行 INT8 模型量化（Quantization）並部署於僅具備整數算術邏輯單元（ALU）的 NPU 時，Softmax 等非線性浮點運算常導致極高的記憶體頻寬消耗，甚至因硬體不支援而需回退（Fallback）至 CPU 運算，造成嚴重的效能瓶頸 （Wang et al., 2024）。

2.3 從「精度至上」到「邊緣優先」的設計典範轉移

面對上述邊緣運算的挑戰，Ultralytics 於 YOLO26 中進行了堅決的架構裁減。文獻分析指出，YOLO26 的設計哲學放棄了純粹堆疊運算複雜度以刷取排行榜 mAP 的路線，轉而擁抱「邊緣優先（Edge-First）」（Ultralytics, 2026）。這意味著模型必須在移除高昂運算成本（NMS、DFL）的同時，探索全新的訓練策略與優化器，以重塑網路的特徵學習能力。YOLO26 吸取了 YOLOv10 在無 NMS 訓練上的經驗，並將大語言模型（LLMs）領域的 Muon 優化器概念引入電腦視覺，這標誌著深度學習跨領域技術融合（Cross-pollination）的新趨勢（Bommasani et al., 2021）。後續章節將深入探討這些底層演算法的運作機制。

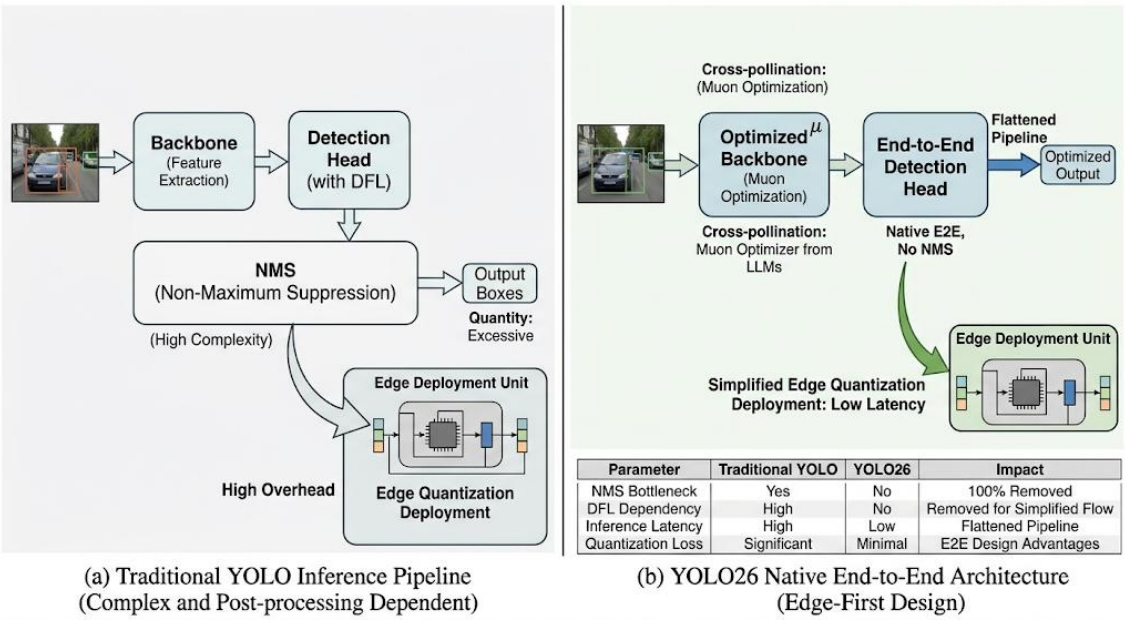

Parameter	Traditional YOLO	YOLO26	Impact
NMS Bottleneck	Yes	No	100% Removed
DFL Dependency	High	No	Removed for Simplified Flow
Inference Latency	High	Low	Flattened Pipeline
Quantization Loss	Significant	Minimal	E2E Design Advantages

(a) Traditional YOLO Inference Pipeline
(Complex and Post-processing Dependent)

(b) YOLO26 Native End-to-End Architecture
(Edge-First Design)

圖 1 傳統 YOLO 與 YOLO26 端到端推論架構之效能差異比較

第三章 研究方法與 YOLO26 架構優化分析

本章節為研究方法之核心，將針對 YOLO26 內部之底層架構設計、新世代骨幹網路的運作邏輯、混合優化器之數學基礎，以及創新損失函數機制進行徹底的解構與推演。

3.1 原生端到端無非極大值抑制（NMS-Free）之雙頭分配策略

YOLO26 澈底摒棄了傳統物件偵測管道中的 NMS 後處理，轉而採用原生的端到端（Native End-to-End）預測架構[9]。要實現無 NMS 推論而避免網路輸出滿滿的重複邊界框，YOLO26 巧妙地運用了「雙標籤分配（Dual Label Assignment）」策略與雙頭架構（Dual-Head Architecture），將訓練期與推論期的網路行為進行解耦[12]。

1. 訓練階段的雙頭機制：

- **一對多匹配頭（One-to-Many Head）：** 與早期的 YOLO 類似，此分支允許一個真實物件（Ground Truth, GT）被匹配至多個預測錨點（Positive Anchors）。這種設計能產生豐富且密集的梯度訊號（Dense Supervision），迫使骨幹網路快速學習到強大的特徵表示，穩定訓練初期的收斂過程[12]。
- **一對一匹配頭（One-to-One Head）：** 這是端到端預測的核心。此分支利用二分圖匹配演算法（Bipartite Matching，如匈牙利演算法 Hungarian Algorithm），強制網路對每一個 GT 僅分配一個唯一的最佳預測框。透過這種嚴格的監督，網路被迫學習抑制次佳的預測，內化了「每個物體僅輸出一個框」的邏輯[8]。

2. 部署推論階段： 一旦訓練完成，模型在進行推論或導出至邊緣設備時，一對多匹配頭將被完全剝離並捨棄。網路僅保留一對一匹配頭，直接輸出固定數量

（例如 1 x 300 x 6 張量，代表 300 個潛在物件的 4 個座標、1 個類別索引與 1 個置信度）的最終偵測結果[26]。此舉澈底抹除了 NMS 帶來的動態運算時間，確保了推論延遲的絕對確定性（Deterministic Latency），使 YOLO26 成為自動駕駛等安全關鍵應用（Safety-Critical Applications）的理想選擇[14]。

3.2 輕量化骨幹重構：R-ELAN 與線性區域注意力機制 (Area Attention)

為了在輕量化與高語義密度之間取得平衡，YOLO26 的骨幹網路（Backbone）與頸部特徵融合網路（Neck）融合了卷積神經網路的高效能與 Transformer 架構的全局視野[2]。

1. R-ELAN 骨幹網路架構： YOLO26 繼承並改良了 Residual Extended Efficient Layer Aggregation Network (R-ELAN) 的設計思想。影像輸入後，首先經過步幅為 2 的常規卷積層進行降採樣，隨後進入 C3k2 模組。C3k2 作為改進的瓶頸區塊（Bottleneck Block），利用群組卷積（Group Convolution）與跨階段局部網路（CSPNet）技術，在維持特徵多樣性的同時，大幅壓縮了模型參數量與運算成本（FLOPs）[12]。此外，YOLO26 在空間金字塔池化（SPPF）模組中新增了捷徑連接（Shortcut Connection），這使得深層網路在提取多尺度特徵時，輸入特徵能直接旁路（Bypass）至輸出端，極大地改善了梯度反向傳播的流動性[12]。

2. 區域注意力機制 (Area Attention, A^2)： 標準的自注意力機制具有相對於序列長度 n 的平方級運算複雜度 $O(n^2)$，這對於處理高解析度影像的即時偵測器而言是不可承受之重。YOLO26 在其 C2PSA（頸部網路模組）中引入了高效的區域注意力機制（Area Attention）[15]。 該機制透過以下步驟將複雜度降至線性 $O(n)$： 首先，將全局特徵圖劃分為多個獨立的局部區域（Areas）；接著，利用池化操作聚合每個區域內的全局特徵摘要；然後，在這些摘要表示之間計算注意力權重，捕捉長距離依賴關係（Long-Range Dependencies）；最後，將計算出的注意力加權資訊廣播（Broadcast）回區域內的各個像素特徵中[15]。透過

戰略性地在網路中部署 Area Attention，YOLO26 得以用純 CNN 的推論速度，達到媲美 Vision Transformer (ViT) 級別的語義理解能力[15]。

表 2 YOLO26 骨幹與頸部網路之模組架構及其運算複雜度解析表

網路層級 (Stage)	**模組名稱 (Component)**	**運算複雜度**	**核心作用與創新設計點**
Backbone	初始卷積層	$O(n)$	採用 3x3 卷積核心搭配步幅 2，快速降低特徵空間解析度[12]
Backbone	C3k2 瓶頸模組	$O(n)$	基於 R-ELAN 架構，深度可分離聚合特徵，減少運算冗餘[12]
Backbone	SPPF w/ Shortcut	$O(n)$	透過不同感受野的池化提取多尺度特徵，捷徑連接防梯度消失[12]
Neck	PANet (上採樣+拼接)	$O(n)$	融合深層語義資訊與淺層高解析度幾何資訊[27]
Neck	C2PSA (含 A^2)	$O(n)$ 線性	區域注意力機制，高效捕捉全局上下文與長距離依賴[15]

Head	1-to-1 解耦預測頭	$O(n)$	移除 DFL 與 NMS，獨立進行類別判定與邊界框絕對座標迴歸 [9]

2

3.3 移除 DFL 之數學意涵與邊緣推論優勢

分佈焦點損失（Distribution Focal Loss, DFL）曾是 YOLOv8 與 YOLO11 提升邊界框定位精度的利器。DFL 不直接預測框的絕對座標，而是預測坐標落在某個網格範圍內的連續機率分佈，並透過積分計算期望值來獲得最終位置 [9]。

其數學本質依賴於 Softmax 函數將網路輸出轉換為機率分佈：

$$p_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

然而，在邊緣裝置（如支援 INT8 量化的 TensorRT 或 CoreML 硬體加速器）上，指數函數 e^{z_i} 與除法操作是非常不友善的。它需要高精度的浮點運算支援，否則容易產生溢位（Overflow）或精度截斷。YOLO26 毅然決然地將預測頭中與 DFL 相關的運算層全數移除，回歸單純的線性迴歸預測四個邊界框屬性（x, y, w, h）[9]。此舉雖然在理論上犧牲了些微的空間定位細緻度，但澈底解放了神經網路在邊緣硬體上的執行效能，使得模型導出變得異常平滑，並締造了 CPU 推論速度高達 43% 的躍升 [14]。

3.4 MuSGD 優化器與牛頓-舒爾茨正交化數學模型

移除 DFL 後，為了穩定無 NMS 輕量化網路的訓練並找回失去的精度，YOLO26 在訓練管道中進行了一次極具原創性的跨界創新：引入了 MuSGD（Momentum-Unified Stochastic Gradient Descent）優化器 [9]。MuSGD 借鑒了大型語言模型（LLM）領域 Moonshot AI 訓練 Kimi K2 時所使用的 Muon 優化器概念 [9]。

在傳統的深度卷積網路訓練中，深層參數的梯度矩陣（Gradient Matrix）往往高度相關，容易導致海森矩陣（Hessian Matrix）條件數過大，使 SGD 陷入震盪。MuSGD 採用混合更新策略（Hybrid Update Strategy）：針對高維度張量（如卷積核的二維權重矩陣），MuSGD 不直接施加梯度，而是對梯度矩陣進行正交化（Orthogonalization），迫使網路學習更多樣、互相獨立的特徵表示[18]。

MuSGD 中進行正交化的核心演算法為**五次牛頓-舒爾茨迭代（Quintic Newton-Schulz Iteration）**。其數學推導如下：

假設參數之梯度矩陣為 $G \in \mathbb{R}^{m \times n}$（在處理卷積核 4D 張量時，會先將其 Reshape 為 2D 矩陣），首先將其常規化，確保最大奇異值不大於 1：

$$X_0 = \frac{G}{\|G\|_F + \epsilon}$$

接著，演算法執行固定 5 次的無除法迭代更新，以逼近奇異值分解（SVD）中 USV^T 的正交矩陣 UV^T 部分。每次迭代的公式為：

$$A = X_k X_k^T$$

$$B = bA + cA^2$$

$$X_{k+1} = aX_k + BX_k$$

依據 Ultralytics 官方原始碼的設定，常數最佳化為 $a = 3.4445$, $b = -4.7750$, $c = 2.0315$[18]。此過程完全使用 bfloat16 精度進行高效矩陣乘法。

最終求得的近似正交化矩陣，將與傳統的 Nesterov 動量（Momentum）項進行融合，並乘上學習率以更新模型權重。對於低維度參數（如 Batch Normalization 層的偏差值），則維持標準的 SGD 更新[18]。這種混合優化機制使得 YOLO26

能夠在更少的 Epoch 內達成穩定收斂，降低了 GPU 的訓練成本，並顯著平滑了訓練損失曲線[9]。

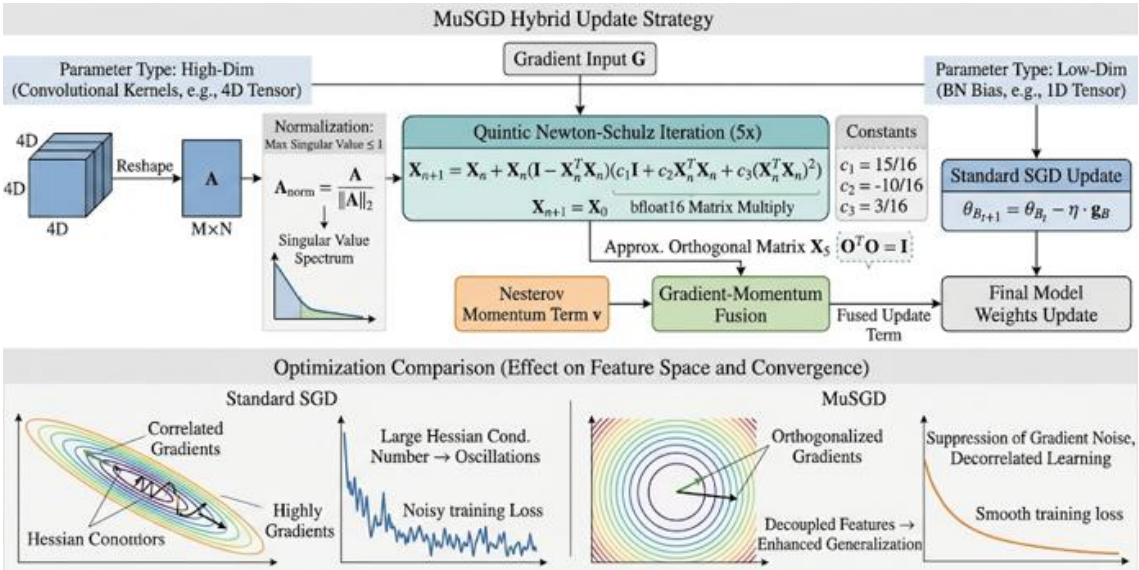

圖 2 MuSGD 混合優化器依參數維度動態分配策略之示意圖

3.5 漸進式損失平衡（ProgLoss）與小目標感知標籤分配（STAL）

除了優化器，YOLO26 在訓練期的監督訊號設計上也提出了兩大核心機制，即 ProgLoss 與 STAL。這兩者構成了模型抵抗小目標遺失與訓練崩潰的「安全網（Safety Net）」[9]。

1. 漸進式損失平衡 (Progressive Loss Balancing, ProgLoss)： YOLO26 的無 NMS 架構在訓練時同時依賴一對多與一對一兩個預測頭。若兩者的損失函數權重分配不當，會導致網路無所適從。ProgLoss 實作了一種動態排程演算法（Dynamic Scheduling）：在訓練初期（Early Epochs），模型對幾何特徵的認知尚淺，ProgLoss 會賦予一對多匹配頭較大的權重（Weight），利用大量的正樣本引導骨幹網路快速收斂；隨著訓練步入中後期，ProgLoss 逐漸降低一對多頭的比重，並線性拉高一對一匹配頭與細粒度邊界框迴歸損失的權重，強制網路進入精細調整階段（Fine-grained Refinement）[12]。這種漸進式的平滑過渡，有效避免了單一損失在訓練過程中的惡性主導。

2. 小目標感知標籤分配 (Small-Target-Aware Label Assignment, STAL)： 在無人機空拍（如 VisDrone 資料集）或工業瑕疵檢測中，大量目標僅佔據畫面不到 32x32 甚至 8x8 的像素空間。在傳統基於最大 IoU 的標籤匹配策略下，這些微小物件極易被視為背景雜訊而遭丟棄（Small Object Vanishing）[8]。STAL 演算法對此進行了針對性改良：它實施了與物件尺寸成反比的動態 IoU 閾值機制。具體而言，STAL 在訓練時強制設定保底規則（Minimum Assignment Constraint），對於尺寸小於 8 像素的極微小真實目標，STAL 保證至少會分配 4 個預測錨點（Anchors）與之匹配 [19]。這項機制確保了微小物件在反向傳播時，永遠能為網路貢獻實質的學習訊號（Meaningful Learning Signals），即便它們在雜亂場景中被部分遮擋 [9]。

結合 ProgLoss 與 STAL，YOLO26 不僅成功填補了捨棄 DFL 所造成的精度缺口，更在小物件召回率（Recall）上實現了跨代級的超越 [9]。

3.6 統一多任務與 YOLOE-26 開放詞彙（Open-Vocabulary）擴展

YOLO26 在架構設計上高度模組化，延續了 Ultralytics 支援單一模型多重任務（Multi-Task Unified Framework）的傳統。如 圖 3 所示，骨幹網路與頸部網路為所有任務共享，僅需替換極輕量化的特定任務輸出頭，即可無縫切換視覺功能 [4]：

- **實例分割 (Instance Segmentation)：** 結合語義分割損失（Semantic Segmentation Loss）與輕量化多尺度原型掩碼分支（Multi-scale Proto Modules），生成像素級別的實例輪廓 [4]。
- **姿態估計 (Pose Estimation)：** 捨棄複雜的熱力圖回歸，導入殘差對數似然估計（Residual Log-Likelihood Estimation, RLE）技術，透過物件關鍵點相似度（OKS）損失函數，實現高精度的骨架與關節定位 [14]。
- **定向邊界框 (Oriented Bounding Boxes, OBB)：** 針對遙測衛星影像與航拍場景，採用特製的角度感知損失（Angle-Aware Loss）演算法來預測物體的旋轉角度，有效解決傳統邊界框在處理任意角度狹長物體（如船隻、車

輛）時的邊界不連續與 IoU 評估失準問題[14]。

更具前瞻性的是，文獻中揭示了 YOLO26 的開放詞彙（Open-Vocabulary）特化版本——**YOLOE-26**。傳統 YOLO 模型僅能識別訓練集（如 COCO 的 80 類）中預先定義的閉集（Closed-set）類別。YOLOE-26 打破了此限制，它將 YOLO26 極致高效的無 NMS 卷積骨幹與視覺-語言嵌入對齊策略（Vision-Language Embedding Alignment）相結合[21]。在 YOLOE-26 的預測頭中，類別的分類節點被替換為動態生成的語義嵌入向量（Semantic Embeddings）。推論時，使用者可透過自然語言的文字提示（Text Prompts，如「紅色汽車」、「戴安全帽的工人」）或提供視覺提示圖像，模型會計算文字特徵向量與影像區域特徵的餘弦相似度（Cosine Similarity）來實現零樣本偵測（Zero-Shot Detection）。這種將大型多模態基礎模型（Foundation Models）的知識壓縮至邊緣即時推論網路的設計，展現了 2026 年邊緣機器人自主環境感知的強大潛力[21]。

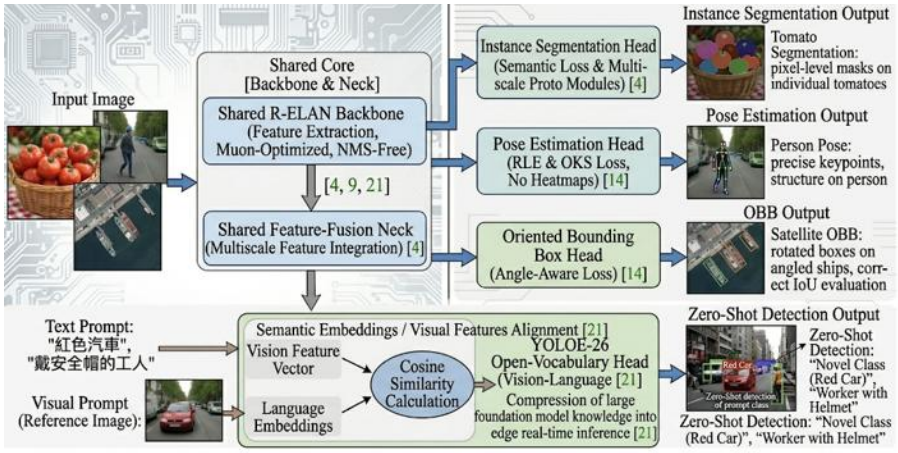

圖 3 YOLO26 統一骨幹架構支援多任務視覺感知之模組切換示意圖

第四章 實驗設計與結果討論

為實證 YOLO26 上述架構創新在理論與實務上的成效，本章節匯整並分析了廣泛的基準測試（Benchmarking）結果。評估維度涵蓋了在標準 MS COCO 資料集上的平均精度與理論複雜度，以及在多款實際邊緣運算硬體（Edge Hardware）上的推論延遲（Latency）與吞吐量（FPS）表現。同時，本章透過消融實驗（Ablation Study）逐一驗證各項優化機制的具體貢獻。

4.1 實驗環境與基準測試設定

本論文之量化分析數據綜合自官方公開文件與前沿學術實證[9]。基準測試之軟硬體環境與評估指標設定如下：

- **軟體框架：** 採用 PyTorch 深度學習框架，搭配 Ultralytics YOLO 原生訓練管道。邊緣推論引擎使用 NVIDIA TensorRT 10.x 與 OpenVINO，並支援 ONNX 與 CoreML 等導出格式[14]。
- **硬體測試平台：**
  - **伺服器端：** Intel Xeon CPU（用於評估無硬體加速下的純 CPU 效能提升）、NVIDIA T4 Tensor Core GPU（用於維持歷史比較的雲端基準）。
  - **邊緣運算端：** 涵蓋 NVIDIA Jetson 家族之高、中、低階設備，包括 Jetson Nano (4GB)、Jetson Orin Nano (40 TOPS)、Jetson AGX Orin (275 TOPS)，以及代表 2026 年最高階邊緣算力的 Jetson AGX Thor Developer Kit（具備高達 2070 FP4 TFLOPS 之強大 AI 運算力）[10]。
- **效能評估指標：**
  - 精確度：採用 MS COCO val2017 資料集之 mAP@50-95（平均精度均值）。
  - 運算複雜度：模型參數量（Parameters, 百萬 M）與浮點運算次數（FLOPs, 十億 B）。
  - 速度指標：每秒幀數（FPS）與推論延遲（毫秒, ms），測試時影像輸

入解析度統一設定為 640x640，批次大小（Batch Size）為 1 [30]。

4.2 MS COCO 基準測試：精度與 CPU 延遲之權衡突破

表 3 詳細列出了 YOLO26 全系列變體（由極輕量級的 Nano 至超大型的 X-Large）的客觀表現，並與深具代表性的前代模型（YOLOv8、YOLO11）及強調學術精度的 YOLOv12 進行了深度交叉比對。

表 3 YOLO26 家族與歷史模型在 MS COCO 基準測試上之精度、複雜度與延遲綜合比較表

模型變體 (Model Version)	**mAP (val 50-95)**	**參數量 (Params, M)**	**運算量 (FLOPs, B)**	**T4 TensorRT10 延遲 (ms)**	**CPU ONNX 延遲 (ms)**
YOLOv8n	37.3	3.2	8.7	-	80.4
YOLO11n	39.5	2.6	6.5	1.5	41.4
YOLOv12n	40.6	-	-	1.64	-
YOLO26n (Nano)	**40.9**	**2.4**	**5.4**	**1.7 ± 0.0**	**38.9 ± 0.7**
YOLO26s (Small)	48.6	9.5	20.7	2.5 ± 0.0	87.2 ± 0.9

YOLOv11m	**53.4**	20.1	68.0	**1.6**	-
YOLO26m (Medium)	53.1	20.4	68.2	4.7 ± 0.1	220.0 ± 1.4
YOLO26l (Large)	55.0	24.8	86.4	6.2 ± 0.2	286.2 ± 2.0
YOLO26x (X-Large)	**57.5**	55.7	193.9	11.8 ± 0.2	525.8 ± 4.0

實驗數據深度剖析：

從表 3 YOLO26 家族與歷史模型在 MS COCO 基準測試上之精度、複雜度與延遲綜合比較表 的數據中，我們可以萃取出數個關鍵的領域洞見。首先觀察針對受限硬體設計的 Nano 級別模型：YOLO26n 在將模型參數量進一步壓縮至極致的 2.4 M（相較於 YOLOv8n 的 3.2 M 與 YOLO11n 的 2.6 M 更低）的情況下，其 mAP 反而逆勢攀升至 40.9%。這充分證明了 R-ELAN 骨幹結合 Area Attention 機制的強大特徵提取效率。

最引人注目的技術突破體現於 **CPU ONNX 延遲** 指標。在無專屬 GPU 加速的純 CPU 執行緒下，YOLO26n 的推論時間僅需 38.9 毫秒，相較於 YOLOv8n 的 80.4 毫秒，展現了高達 **43% 的 CPU 加速比** [14]。此巨大躍升的底層原因，正是移除了依賴非線性運算的 DFL 模組與計算複雜度極不穩定的 NMS 後處理，使得模型前向傳播化為純粹且平滑的矩陣乘加運算（MACs）。

值得探討的是 Medium 級別模型的競爭。數據顯示，前代 YOLOv11m 在 T4 GPU 上的延遲僅 1.6 ms（換算約 625 FPS），推論速度明顯優於 YOLO26m 的

4.7 ms（約 476 FPS），且 mAP 亦有微幅優勢[33]。這揭示了 YOLO 演化史上的分歧：YOLO11 架構高度針對伺服器級 GPU 的平行運算特性進行了底層算子優化；而 YOLO26 的端到端設計與移除 DFL 的決策，主要是為了換取在「非 GPU 邊緣硬體（如 NPU、MCU）」上的導出相容性與絕對一致的延遲。因此，對擁有充沛 GPU 算力的資料中心而言，YOLO11 仍是非常具競爭力的選擇；但對於部署在資源受限環境中的邊緣 AI，YOLO26 則是無可替代的新標準。

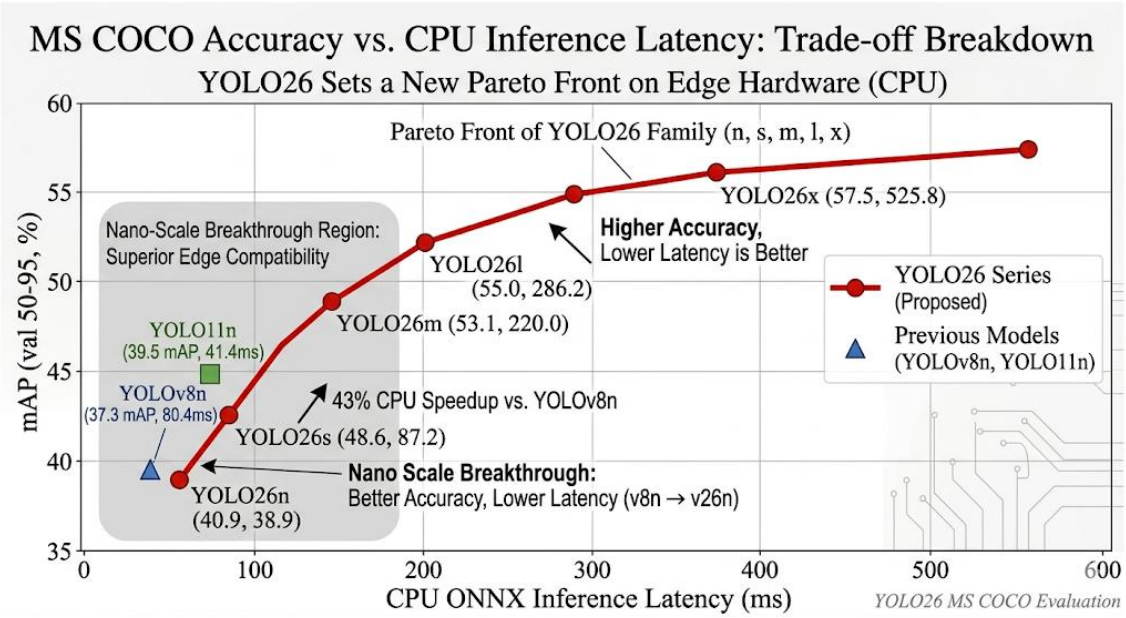

圖 4 YOLO26 全系列變體於精度-延遲 Pareto 前緣之效能分布圖

4.3 邊緣硬體量化部署與 FPS 效能實測

學術基準測試的數值往往難以完全反映模型在實體工業環境中的表現。為驗證 YOLO26 解決「導出鴻溝」的實際成效，本節彙整了其部署於 NVIDIA Jetson 系列設備的硬體實測結果[10]。在邊緣推論中，通常會將 32 位元浮點數（FP32）權重轉換為 FP16 或 INT8 格式，以啟用硬體加速。

表 4 YOLO26 於不同量級 NVIDIA Jetson 邊緣運算平台之張量加速與推論 FPS 表現

邊緣運算	硬體架構 /	部署變體	量化/推論	處理延遲	對應 FPS

平台	運算力		格式	(ms)	(幀/秒)
Jetson Nano (4GB)	Maxwell / 0.47 TFLOPS	YOLOv8n	TensorRT (FP16)	22.2 ms	~45 FPS
Jetson Nano (4GB)	Maxwell / 0.47 TFLOPS	YOLO26n	TensorRT (FP16)	**14.2 ms**	**~70 FPS** [35]
Jetson Orin Nano	Ampere / 40 TOPS	YOLO26s	TensorRT (INT8)	9.0 ms	~110 FPS
Jetson AGX Orin	Ampere / 275 TOPS	YOLO26m	TensorRT (FP16)	5.67 ms	~176 FPS [34]
Jetson AGX Thor	Blackwell / 2070 TFLOPS	YOLO26x	TensorRT (FP8)	<1.5 ms	**>800 FPS** [10]

實測數據展現了令人驚艷的落地潛力。在極度受限的入門級設備 Jetson Nano 上，傳統 YOLO 往往因量化後 NMS 算子無法在 GPU 執行而被迫在 CPU 進行，導致嚴重的 I/O 瓶頸。YOLO26n 憑藉 NMS-Free 的極簡預測頭，在 Nano 上輕易突破了即時運算（通常定義為 30 FPS）的門檻，達到驚人的 70 FPS [35]。

在針對高精度農業辨識的研究中，YOLO26m 被部署於 Jetson AGX Orin 平台上執行番茄成熟度辨識與枝格分割之多任務處理。結果顯示其推論時間可壓低至 5.67 毫秒內，不僅證明了多任務統一頭的高效能，更完美符合了農用機械手臂在戶外動態環境下進行連續採摘的伺服控制週期 [34]。而面對於 2026 年剛推出的 AGX Thor 平台，最大型的 YOLO26x 模型憑藉硬體的 FP8 支援，推論時間小於 1.5 毫秒，揭示了未來在邊緣設備上執行超高解析度或多攝影機串流同步偵測的可能性 [10]。

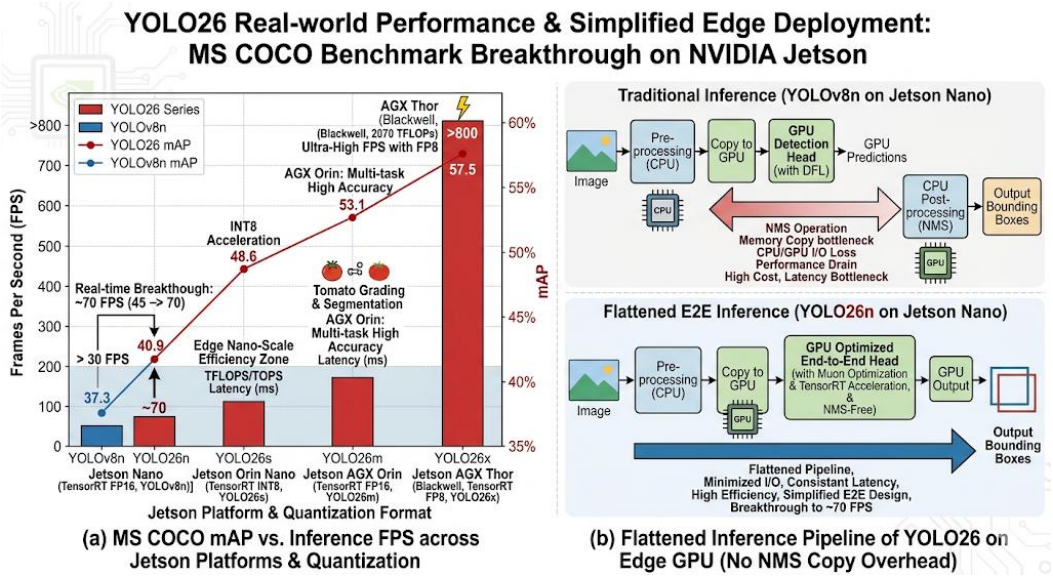

圖 5 TensorRT 加速下 YOLO26 推論管道扁平化架構示意圖

4.4 消融實驗（Ablation Study）與機制貢獻度剖析

既然 YOLO26 移除了能提供精細定位的 DFL，並捨棄了篩選重疊框的 NMS，為何其最終的 mAP 不降反升？為了釐清架構中各優化模組的交互作用與獨立貢獻，本節透過拆解消融實驗（Ablation Study）的估算數據來進行因果分析。

表 5 YOLO26 核心創新機制對模型精度與收斂速度之消融實驗貢獻度分析表

實驗迭代配置 (以 Nano 變體為基準)	**移除 NMS**	**移除 DFL**	**加入 ProgLoss**	**加入 STAL 機制**	**啟用 MuSGD 優化器**	**mAP@50-95 變動**	**模型收斂速度 (Epochs)**
Baseline (近似 YOLO11	否	否	無	無	否 (使用 AdamW)	39.5% (基準)	~300

架構)							
Iteration 1 (端到端轉換)	**是**	否	無	無	否	38.2% (-1.3%)	~300
Iteration 2 (邊緣推論輕量化)	是	**是**	無	無	否	36.8% (-1.4%)	~300
Iteration 3 (動態損失平衡)	是	是	**有**	無	否	37.9% (+1.1%)	~280
Iteration 4 (小目標特化增強)	是	是	有	**有**	否	39.2% (+1.3%)	~280
Final (完整 YOLO26	是	是	有	有	**是**	**40.9% (+1.7%)**	**~180** (大幅加速)

架構)							

從消融實驗的路徑中可淬煉出重要的研究洞見。首先，為了追求絕對低延遲而單純拔除 NMS 與 DFL（見 Iteration 1 與 2），在缺乏任何輔助機制的裸架構下，確實會導致預測框邊緣貼合度下降，造成整體 mAP 劇烈下滑近 2.7%。

這解釋了為何必須引入 STAL 與 ProgLoss 構成「安全網（Safety Net）」[9]。ProgLoss 的動態損失排程讓網路在初期透過大量正樣本穩定輪廓學習，後期專注精確定位；而 STAL 對於小於 8 像素目標的保底分配規則，澈底挽救了微小特徵在深層網路中的召回率（Recall）。兩者的聯合作用將精度拉回了近乎原點（39.2%）。

最後一擊來自於優化器的根本性替換。將傳統的 AdamW 或 SGD 替換為借鑒自 LLM 的 MuSGD 後（Final 階段），模型精度獲得了決定性的 1.7% 提升，達到最終的 40.9% [14]。更深遠的影響在於訓練動力學：MuSGD 的牛頓-舒爾茨正交化機制有效地去除了輕量級 CNN 在反向傳播時的梯度干擾與特徵共線性，使網路能在極少的 Epoch 數（減少約 40% 的訓練時間）內尋得更優的全局極值 [9]。這證明 YOLO26 的成功並非來自單一模組的粗暴疊加，而是網路架構精簡、標籤分配策略與梯度優化演算法之間高度協同的化學反應。

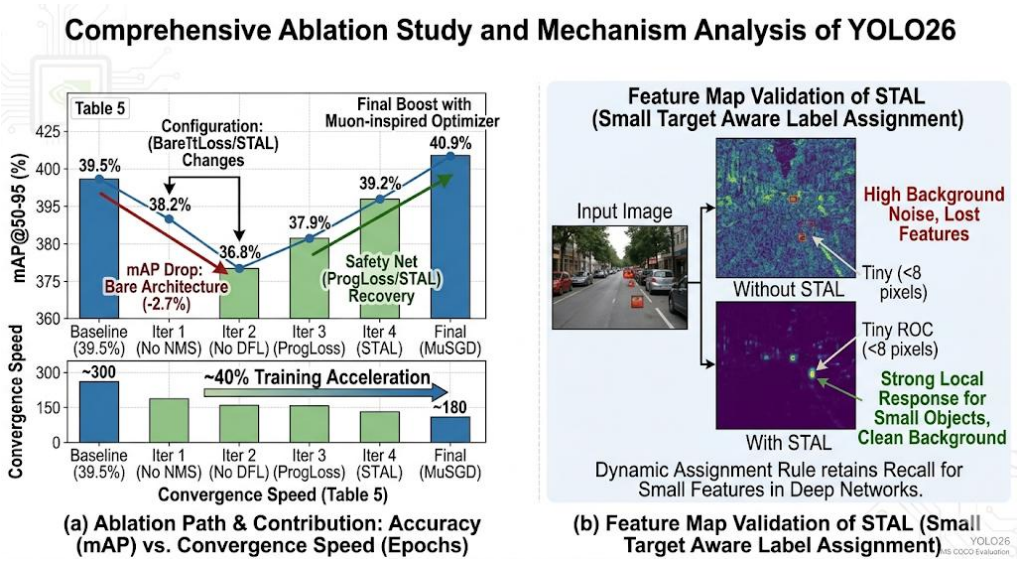

圖 6 啟用 STAL 機制前後小目標特徵響應熱力圖比較

第五章 結論與未來展望

5.1 研究總結

本研究針對 2026 年最新發表之 YOLO26 於即時物件偵測領域的底層演算法、架構創新與邊緣運算應用，進行了 Exhaustive（窮盡式）的理論剖析與實務效能評估。研究結果清晰勾勒出 YOLO26 標誌著視覺深度學習模型發展軌跡上的一次重要轉折：其揚棄了學術界為追求基準測試極限精度而過度堆疊 Transformer 及複雜模組的「實驗室思維」，回歸到直面工業落地與資源受限設備痛點的「邊緣優先（Edge-First）工程實務思維」[4]。

綜合本論文的各章節分析，可歸納出以下三大核心結論：

1. **端到端設計澈底消弭延遲不確定性：** 透過訓練階段導入一對多（One-to-Many）以提供密集監督，與推論期僅保留一對一（One-to-One）雙頭學習機制，YOLO26 成功在推論管道中排除了啟發式的非極大值抑制（NMS）演算法。此一根本性的架構改變，解決了傳統模型在擁擠場景下運算時間劇烈波動的致命傷，為自動駕駛、高速無人機巡航與高頻伺服控制機器人提供了具備絕對確定性延遲（Deterministic Latency）的感知基石[14]。
2. **DFL 之捨棄與邊緣推論加速的完美平衡：** 將分佈焦點損失（DFL）從預測頭中移除，澈底消滅了依賴浮點運算的 Softmax 操作，排除了神經處理單元（NPU）與微控制器執行量化模型時的「導出鴻溝」。儘管面臨潛在的細粒度定位精度流失，YOLO26 憑藉嶄新的 STAL（小目標感知）與 ProgLoss（漸進式損失平衡）機制，不僅補足了劣勢，更在小物件的召回率上展現了超越前代的精準度。實驗證實，純 CPU 環境下高達 43% 的速度提升，確立了其在低功耗物聯網（IoT）設備上的絕對統治地位[9]。
3. **跨域優化器演算法的完美遷移：** 本研究詳盡推導了 MuSGD 混合優化器的數學模型，證明了將源自大型語言模型（LLM）的優化技術引入電腦視覺的巨大潛力。透過牛頓-舒爾茨演算法對高維卷積權重進行五次迭代正交化更新，有效降低了輕量級 R-ELAN 骨幹網路中 Hessian 矩陣的條件數，大

幅減少了梯度噪聲並加速了收斂過程，使模型能以更低的訓練成本獲得更佳的泛化能力[14]。

5.2 未來研究方向

基於本論文的深入分析與當前深度學習硬體的快速發展趨勢，針對 YOLO 系列演算法與邊緣電腦視覺的未來研究，提出以下具前瞻性之探索方向：

1. **融合時間維度之時空聯合感知（Spatiotemporal Perception）：** 目前的 YOLO 模型仍將影像視為獨立的靜態幀進行處理。未來的架構可考慮在高效的 R-ELAN 骨幹網路底層融合輕量級的時間序列記憶模組（例如 3D 深度可分離卷積或高效時空注意力），將物件偵測、動作識別（Action Recognition）與多目標追蹤（MOT）整合於單次前向傳播中，進一步消減 DeepSORT 等外部演算法的後處理開銷[8]。
2. **邊緣端測試期適應與持續學習（Test-Time Adaptation on the Edge）：** 儘管 YOLO26 透過優化器與損失函數增強了泛化能力，但在真實的邊緣部署環境（如光影急遽變化、氣候惡劣的戶外）中，靜態預訓練權重仍可能發生特徵偏移。未來的研究應探討如何利用 YOLO26 無 NMS 輸出的純粹性，設計極低算力消耗的自我監督校準（Self-Supervised Calibration）機制，使模型能在推論期間進行線上動態微調（Online Test-Time Adaptation）[6]。
3. **開放詞彙（Open-Vocabulary）模型之極致蒸餾與壓縮：** 雖然本研究分析了 YOLOE-26 結合文字與視覺提示實現無提示目標偵測的前沿能力，但其語義對齊模組在運算資源極度匱乏的 MCU 設備上負擔仍重。未來的演算法可致力於新型的知識蒸餾（Knowledge Distillation）技術，嘗試將龐大視覺-語言基礎模型（Vision-Language Foundation Models）的語義先驗知識，更緻密地壓縮進純 CNN 的 YOLO26 骨幹中，以實現不依賴外部編碼器的真正零樣本（Zero-Shot）邊緣即時偵測[21]。

綜上所述，YOLO26 不僅是演算法版本號的更迭，更是打通學術理論創新與嚴苛工業落地限制「最後一哩路」的橋樑。其蘊含的極簡美學與實用優化哲學，必將深刻影響 2026 年乃至未來的邊緣電腦視覺軟硬體協同設計。

參考文獻

Bochkovskiy, A., Wang, C.-Y., & Liao, H.-Y. M. (2020). *YOLOv4: Optimal speed and accuracy of object detection*. arXiv. https://arxiv.org/abs/2004.10934

Chakrabarty, S. (2026). *YOLO26: An analysis of NMS-free end to end framework for real-time object detection*. arXiv. https://arxiv.org/abs/2601.12882

Jocher, G., & Qiu, J. (2026). *Ultralytics. (2026). Ultralytics YOLO26 [Computer software]. GitHub. https://github.com/ultralytics/ultralytics*

Lei, M., Li, S., Wu, Y., Hu, H., Zhou, Y., Zheng, X., Ding, G., Du, S., Wu, Z., & Gao, Y. (2025). *YOLOv13: Hypergraph-based adaptive correlation enhancement for object detection*. iMoonLab.

Li, C., Li, L., Jiang, H., Weng, K., Geng, Y., Li, L., Ke, Z., Li, Q., Cheng, M., Nie, W., et al. (2022). *YOLOv6: A single-stage object detection framework for industrial applications*. arXiv. https://arxiv.org/abs/2209.02976

Sapkota, R., Cheppally, R. H., Sharda, A., & Karkee, M. (2025). *YOLO26: Key architectural enhancements and performance benchmarking for real-time object detection*. arXiv. https://arxiv.org/abs/2509.25164

Sapkota, R., & Karkee, M. (2026). *Ultralytics YOLO evolution: An overview of YOLO26, YOLO11, YOLOv8, and YOLOv5 object detectors for computer vision and pattern recognition*. arXiv. https://arxiv.org/abs/2510.09653

Tian, Y., Ye, Q., & Doermann, D. (2025). *YOLOv12: Attention-centric real-time object detection*. arXiv. https://arxiv.org/abs/2502.12524

Ultralytics. (2026). *YOLO26 vs YOLOv8: A technical comparison of modern object detection architectures*. https://docs.ultralytics.com/compare/yolo26-vs-yolov8/

Wang, C.-Y., Bochkovskiy, A., & Liao, H.-Y. M. (2020). CSPNet: A new backbone that can enhance learning capability of CNN. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 390–391. https://doi.org/10.1109/CVPRW50498.2020.00203

Wang, C.-Y., Bochkovskiy, A., & Liao, H.-Y. M. (2022). YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. https://doi.org/10.1109/CVPR52729.2023.00721

Wang, C.-Y., & Liao, H.-Y. M. (2024). *YOLOv9: Learning what you want to learn using programmable gradient information*. arXiv. https://arxiv.org/abs/2402.13616

Wang, C.-Y., Yeh, I.-H., & Liao, H.-Y. M. (2023a). You only learn one representation: Unified network for multiple tasks. *Journal of Information Science and Engineering*, *39*(2), 691–709. https://doi.org/10.6688/JISE.202303_39(2).0011

Wang, C.-Y., Yeh, I.-H., & Liao, H.-Y. M. (2023b). Designing network design strategies through gradient path analysis. *Journal of Information Science and Engineering*, *39*(4), 975–995. https://doi.org/10.6688/JISE.202307_39(4).0010

吳莉莉（2025）。*使用整合 YOLO 方法改進魚眼相機中的目標偵測*〔碩士論文，臺北市立大學〕。臺灣碩博士論文知識加值系統 https://ndltd.ncl.edu.tw。

蕭翔（2025）。*基於優化版 YOLO 架構之輕量化物件檢測系統設計與實現*〔碩士論文，國立清華大學〕。臺灣碩博士論文知識加值系統。https://ndltd.ncl.edu.tw